



Maestría en Ciencia de datos e Información – Matemáticas

Tarea 2. Resolución de Problemas

Alumno: Chanona Leyva José Luis
24 de septiembre de 2026

Contenido

Maestría en Ciencia de Datos e Información | Matemáticas

Introducción	1
Ejercicio 1. Función de densidad	1
Ejercicio 2. Distribución normal.....	4
Ejercicio 3. Temperaturas de Chiapas	6
Ejercicio 4. Teorema de Bayes	14
Ejercicio 5. Análisis de componentes principales.....	16
Ejercicio 6. Genes mirror geography within Europe	25
Referencias.....	26

Introducción

Esta tarea reúne aplicaciones de probabilidad, estadística y reducción de dimensionalidad. Primero se resuelve una función de densidad y se calculan probabilidades de una distribución normal. Después se ajustan modelos lineal, cuadrático y cúbico a la temperatura media anual de Chiapas entre 1993 y 2023 mediante mínimos cuadrados. Finalmente se aplica el teorema de Bayes, se desarrolla un análisis de componentes principales con la base USArrests y se relaciona el PCA con el artículo Genes mirror geography within Europe. El propósito es mostrar cada procedimiento con claridad y explicar qué significa cada resultado.

Herramientas y criterios de desarrollo

Los ejercicios 1, 2 y 4 se resuelven analíticamente. Para los ejercicios 3 y 5 se utiliza R para calcular los ajustes, organizar los resultados y generar las figuras; en este documento se incluyen únicamente los fragmentos relacionados con cada resultado. El código completo se entrega por separado en el repositorio de GitHub. Las tablas, figuras y fragmentos de código tienen una leyenda para facilitar su consulta.

Ejercicio 1. Función de densidad

Enunciado: (15 puntos) La función de densidad de una variable aleatoria está dada por $f(x) = a + bx^2$, $0 \leq x \leq 1$; $f(x) = 0$, en otro caso. Si la esperanza es $E(X) = \frac{3}{5}$. Encuentre a y b.

Para que $f(x)$ sea una función de densidad, el área total bajo la curva debe ser 1. Por eso se plantea la primera ecuación integrando entre 0 y 1:

$$\int_0^1 (a + bx^2) dx = 1$$

Primero se integra cada término. La integral de a es ax y la integral de bx^2 es $bx^3/3$:

$$\left[ax + \frac{bx^3}{3} \right]_0^1 = 1$$

Ahora se sustituyen los límites. En el límite superior $x = 1$ y en el inferior $x = 0$:

$$\left(a \cdot 1 + b \cdot \frac{1^3}{3} \right) - \left(a \cdot 0 + b \cdot \frac{0^3}{3} \right) = 1$$

$$a + \frac{b}{3} - 0 = 1$$

$$a + \frac{b}{3} = 1 \quad (1)$$

También se utiliza la definición de esperanza para una variable continua:

$$E(X) = \int_0^1 x f(x) dx = \int_0^1 x(a + bx^2) dx$$

Se distribuye x dentro del paréntesis: $x \cdot a = ax$ y $x \cdot bx^2 = bx^3$:

$$E(X) = \int_0^1 (ax + bx^3) dx$$

$$E(X) = \left[\frac{ax^2}{2} + \frac{bx^4}{4} \right]_0^1$$

$$E(X) = \left(a \cdot \frac{1^2}{2} + b \cdot \frac{1^4}{4} \right) - \left(a \cdot \frac{0^2}{2} + b \cdot \frac{0^4}{4} \right)$$

$$E(X) = \frac{a}{2} + \frac{b}{4} = \frac{3}{5} \quad (2)$$

Ahora se resuelve el sistema. De (1):

$$a + \frac{b}{3} = 1$$

$$a = 1 - \frac{b}{3}$$

Sustituyendo esta expresión de a en (2):

$$\frac{\left(1 - \frac{b}{3}\right)}{2} + \frac{b}{4} = \frac{3}{5}$$

Se divide cada término del primer paréntesis entre 2:

$$\frac{1}{2} - \frac{b}{6} + \frac{b}{4} = \frac{3}{5}$$

Se reducen los términos que contienen b usando denominador común 12: $-\frac{b}{6} = -2\frac{b}{12}$ y $\frac{b}{4} = 3\frac{b}{12}$:

$$\frac{1}{2} + \left(-2\frac{b}{12} + 3\frac{b}{12}\right) = \frac{3}{5}$$

$$\frac{1}{2} + \frac{b}{12} = \frac{3}{5}$$

Se resta $1/2$ en ambos lados. Como $\frac{3}{5} = \frac{6}{10}$ y $\frac{1}{2} = \frac{5}{10}$, la diferencia es $1/10$:

$$\frac{b}{12} = \frac{3}{5} - \frac{1}{2} = \frac{6}{10} - \frac{5}{10} = \frac{1}{10}$$

Se multiplica por 12 en ambos lados para despejar b :

$$b = 12 \cdot \left(\frac{1}{10}\right) = \frac{12}{10} = \frac{6}{5}$$

Finalmente, se obtiene a sustituyendo $b = \frac{6}{5}$ en $a = 1 - \frac{b}{3}$

$$a = 1 - \frac{\left(\frac{6}{5}\right)}{3} = 1 - \frac{6}{15} = 1 - \frac{2}{5} = \frac{3}{5}$$

Validación: se sustituye $f(x) = \frac{3}{5} + \left(\frac{6}{5}\right)x^2$. La función es no negativa en $[0,1]$ porque ambos términos son no negativos. Además, la primera ecuación confirma que el área total es 1 y la segunda confirma que $E(X) = \frac{3}{5}$.

Por lo tanto, los valores buscados son:

$$a = \frac{3}{5} \text{ y } b = \frac{6}{5}$$

Ejercicio 2. Distribución normal

Enunciado: La estatura de las mujeres adultas en Estados Unidos se distribuye normalmente con media $\mu = 64.5$ pulgadas y desviación estándar $\sigma = 2.4$ pulgadas. Hallar la probabilidad de que una mujer elegida al azar mida

- (a) menos de 63 pulgadas;
- (b) entre 63 y 70 pulgadas;
- (c) Alice mide 72 pulgadas. ¿Qué porcentaje de mujeres mide menos que Alicia?

Se define X como la estatura de una mujer elegida al azar. Entonces $X \sim N(\mu = 64.5, \sigma = 2.4)$. Para comparar cualquier estatura con la normal estándar, se resta la media y se divide entre la desviación estándar: $z = \frac{(x - \mu)}{\sigma}$. Después se consulta la función acumulada $\Phi(z)$, que representa $P(Z \leq z)$.

a) Menos de 63 pulgadas

$$z = \frac{(63 - 64.5)}{2.4}$$

$$z = \frac{(-1.5)}{2.4} = -0.625$$

$$P(X < 63) = P(Z < -0.625) = \Phi(-0.625)$$

$$\Phi(-0.625) \approx 0.2660$$

La probabilidad es aproximadamente 0.2660, es decir, 26.60 %.

b) Entre 63 y 70 pulgadas

$$z_1 = \frac{(63 - 64.5)}{2.4} = \frac{(-1.5)}{2.4} = -0.625$$

$$z_2 = \frac{(70 - 64.5)}{2.4} = \frac{5.5}{2.4} = 2.2917$$

$$P(63 < X < 70) = P(-0.625 < Z < 2.2917)$$

$$P(63 < X < 70) = \Phi(2.2917) - \Phi(-0.625)$$

$$P(63 < X < 70) \approx 0.9890 - 0.2660 = 0.7230$$

La probabilidad es aproximadamente 0.7230, es decir, 72.30 %.

c) Menos que Alice

$$z = \frac{(72 - 64.5)}{2.4}$$

$$z = \frac{7.5}{2.4} = 3.125$$

$$P(X < 72) = P(Z < 3.125) = \Phi(3.125)$$

$$\Phi(3.125) \approx 0.9991$$

Por lo tanto, aproximadamente 99.91 % de las mujeres mide menos que Alice. El resultado es muy alto porque 72 pulgadas se encuentran más de tres desviaciones estándar por encima de la media.

Ejercicio 3. Temperaturas de Chiapas

Enunciado: (25 puntos) Realice un análisis de las temperaturas promedio de uno de los 32 estados de México de los años 1993 al 2023 aproximando a través del método de mínimos cuadrados para el caso lineal, cuadrático y cúbico. El caso lineal y cuadrático se explicaron en clase, para en caso cúbico es necesario utilizar el mismo razonamiento y deducir las fórmulas resultantes. Explicar paso a paso el método. Los estados y el periodo se asignarán de forma personalizada. Los datos provienen del Servicio Meteorológico Nacional.

Para este trabajo se utiliza exclusivamente el estado de Chiapas. Los 31 valores proporcionados se ordenan de 1993 a 2023, y la variable explicativa se centra en 2008 para simplificar las sumas: $t = \text{año} - 2008$. Así, t toma los valores de -15 a 15 .

Datos utilizados

Año / Year	t	Temperatura (°C) / Temperature (°C)
1993	-15	23.9
1994	-14	24.0
1995	-13	23.9
1996	-12	23.8
1997	-11	24.0
1998	-10	23.8
1999	-9	23.5
2000	-8	23.6
2001	-7	23.8
2002	-6	24.0
2003	-5	24.0
2004	-4	24.0
2005	-3	24.7
2006	-2	25.4
2007	-1	25.0
2008	0	24.5
2009	1	24.4
2010	2	24.3
2011	3	24.3
2012	4	24.6
2013	5	24.9

Año / Year	t	Temperatura (°C) / Temperature (°C)
2014	6	24.5
2015	7	25.2
2016	8	26.1
2017	9	25.6
2018	10	25.3
2019	11	25.7
2020	12	25.5
2021	13	25.2
2022	14	24.5
2023	15	25.4

Tabla 1. Datos de temperatura media anual de Chiapas y variable centrada.

Método de mínimos cuadrados

La idea es elegir los coeficientes que hagan lo más pequeña posible la suma de los cuadrados de los errores. Si y_i es la temperatura observada y $\hat{y}_i$ la temperatura estimada, el error es $e_i = y_i - \hat{y}_i$ y se minimiza $S = \sum e_i^2$.

Caso lineal

$$\hat{y} = a + bt$$

Para obtener a y b se define la suma de cuadrados de los errores. Se sustituye $\hat{y}_i = a + bt_i$ en $e_i = y_i - \hat{y}_i$:

$$S(a, b) = \sum [y_i - (a + bt_i)]^2$$

Se deriva S respecto de cada coeficiente y se iguala a cero porque buscamos el punto donde S es mínimo:

$$\frac{\partial S}{\partial a} = -2\sum [y_i - (a + bt_i)] = 0$$

$$\sum y_i - na - b\sum t_i = 0$$

$$na + b\sum t = \sum y$$

$$\frac{\partial S}{\partial b} = -2\sum t_i [y_i - (a + bt_i)] = 0$$

$$\sum t_i y_i - a\sum t_i - b\sum t_i^2 = 0$$

$$a\sum t + b\sum t^2 = \sum ty$$

Estas son las dos ecuaciones normales. Ahora se sustituyen los valores calculados para Chiapas: $n = 31$, $\Sigma t = 0$, $\Sigma t^2 = 2480$, $\Sigma y = 761.4$ y $\Sigma ty = 155.1$.

$$31a + b(0) = 761.4$$

$$31a = 761.4$$

$$a = \frac{761.4}{31} = 24.56129032$$

$$a(0) + 2480b = 155.1$$

$$2480b = 155.1$$

$$b = \frac{155.1}{2480} = 0.06254032$$

Por lo tanto, el modelo lineal estimado es:

$$\hat{y} = 24.56129032 + 0.06254032t$$

Como los valores de t son simétricos, $\Sigma t = 0$. Entonces $a = \frac{\Sigma y}{n}$ y $b = \frac{\Sigma ty}{\Sigma t^2}$. El coeficiente a representa la temperatura estimada en 2008 y b representa el cambio promedio por año.

Caso cuadrático

$$\hat{y} = a + bt + ct^2$$

Ahora se agrega el término ct^2 . La suma de cuadrados queda:

$$S(a, b, c) = \Sigma [y_i - (a + bt_i + ct_i^2)]^2$$

Al derivar respecto de a , b y c , se obtiene una ecuación normal por cada coeficiente:

$$\frac{\partial S}{\partial a} = 0 \rightarrow na + b\Sigma t + c\Sigma t^2 = \Sigma y$$

$$\frac{\partial S}{\partial b} = 0 \rightarrow a\Sigma t + b\Sigma t^2 + c\Sigma t^3 = \Sigma ty$$

$$\frac{\partial S}{\partial c} = 0 \rightarrow a\Sigma t^2 + b\Sigma t^3 + c\Sigma t^4 = \Sigma t^2 y$$

Como $\Sigma t = 0$ y $\Sigma t^3 = 0$, se sustituyen las sumas en las tres ecuaciones:

$$31a + 2480c = 761.4$$

$$2480b = 155.1$$

$$2480a + 356624c = 60913.5$$

Primero se despeja b de la segunda ecuación:

$$b = \frac{155.1}{2480} = 0.06254032$$

Para obtener a y c, se despeja a de la primera ecuación:

$$31a = 761.4 - 2480c$$

$$a = \frac{761.4}{31} - \left(\frac{2480}{31}\right)c = 24.56129032 - 80c$$

Se sustituye esta expresión en la tercera ecuación:

$$2480(24.56129032 - 80c) + 356624c = 60913.5$$

$$60912 - 198400c + 356624c = 60913.5$$

$$158224c = 1.5$$

$$c = \frac{1.5}{158224} = 0.00000948023$$

Finalmente se sustituye c en a:

$$a = 24.56129032 - 80(0.00000948023) = 24.56053190$$

$$\hat{y} = 24.56053190 + 0.06254032t + 0.00000948023t^2$$

El término ct^2 permite representar una curvatura que una recta no puede capturar. En este caso c es positivo, aunque su valor es muy pequeño.

Caso cúbico y deducción de las fórmulas

$$\hat{y} = a + bt + ct^2 + dt^3$$

Se define la suma de cuadrados para el modelo cúbico:

$$S(a, b, c, d) = \sum [y_i - (a + bt_i + ct_i^2 + dt_i^3)]^2$$

Al derivar respecto de a, b, c y d, se obtiene una ecuación normal por cada coeficiente:

$$\frac{\partial S}{\partial a} = 0 \rightarrow na + b\sum t + c\sum t^2 + d\sum t^3 = \sum y$$

$$\frac{\partial S}{\partial b} = 0 \rightarrow a\sum t + b\sum t^2 + c\sum t^3 + d\sum t^4 = \sum ty$$

$$\frac{\partial S}{\partial c} = 0 \rightarrow a\Sigma t^2 + b\Sigma t^3 + c\Sigma t^4 + d\Sigma t^5 = \Sigma t^2 y$$

$$\frac{\partial S}{\partial d} = 0 \rightarrow a\Sigma t^3 + b\Sigma t^4 + c\Sigma t^5 + d\Sigma t^6 = \Sigma t^3 y$$

Como t va de -15 a 15 , las potencias impares se cancelan por simetría: $\Sigma t = \Sigma t^3 = \Sigma t^5 = 0$. Al sustituir las sumas conocidas, el sistema queda:

$$31a + 2480c = 761.4$$

$$2480b + 356624d = 155.1$$

$$2480a + 356624c = 60913.5$$

$$356624b + 60965840d = 19520.7$$

Las ecuaciones pares permiten calcular a y c ; las impares permiten calcular b y d . Primero se resuelve el sistema de a y c :

$$31a + 2480c = 761.4 \rightarrow a = 24.56129032 - 80c$$

$$2480(24.56129032 - 80c) + 356624c = 60913.5$$

$$60912 - 198400c + 356624c = 60913.5$$

$$158224c = 1.5 \rightarrow c = \frac{1.5}{158224} = 0.00000948023$$

$$a = 24.56129032 - 80(0.00000948023) = 24.56053190$$

Ahora se resuelve el sistema de b y d . De la primera ecuación impar:

$$2480b + 356624d = 155.1 \rightarrow b = \frac{155.1}{2480} - \left(\frac{356624}{2480}\right)d$$

$$b = 0.06254032 - 143.8d$$

Se sustituye en la segunda ecuación impar:

$$356624(0.06254032 - 143.8d) + 60965840d = 19520.7$$

$$22303.38 - 51282531.2d + 60965840d = 19520.7$$

$$9683308.8d = -2782.68$$

$$d = -\frac{2782.68}{9683308.8} = -0.00028736871$$

$$b = 0.06254032 - 143.8(-0.00028736871) = 0.10386394$$

Por lo tanto, el modelo cúbico completo es:

$$\hat{y} = 24.56053190 + 0.10386394t + 0.00000948023t^2 - 0.00028736871t^3$$

Las fórmulas generales obtenidas al resolver los dos sistemas son:

$$a = [\Sigma y \cdot \Sigma t^4 - \Sigma t^2 \cdot \Sigma t^2 y] / [n \cdot \Sigma t^4 - (\Sigma t^2)^2]$$

$$c = [n \cdot \Sigma t^2 y - \Sigma t^2 \cdot \Sigma y] / [n \cdot \Sigma t^4 - (\Sigma t^2)^2]$$

$$b = [\Sigma ty \cdot \Sigma t^6 - \Sigma t^4 \cdot \Sigma t^3 y] / [\Sigma t^2 \cdot \Sigma t^6 - (\Sigma t^4)^2]$$

$$d = [\Sigma t^2 \cdot \Sigma t^3 y - \Sigma t^4 \cdot \Sigma ty] / [\Sigma t^2 \cdot \Sigma t^6 - (\Sigma t^4)^2]$$

Cantidad / Quantity	Valor
n	31
Σt	0
Σt^2	2480
Σt^3	0
Σt^4	356624
Σt^5	0
Σt^6	60965840
Σy	761.4000
Σty	155.1000
$\Sigma t^2 y$	60913.5000
$\Sigma t^3 y$	19520.7000

Tabla 2. Sumas utilizadas en las ecuaciones normales.

Fragmento R · Ejercicio 3

```
01 # ES/EN: Datos de temperatura de Chiapas, 1993-2023 / 1993-2023
02 # ES/EN: Se crea la secuencia de años / Create the year sequence.
03 años <- 1993:2023
04 # ES/EN: Se capturan los 31 valores entregados / Enter the 31 supplied values.
05 temperatura <- c(23.9, 24, 23.9, 23.8, 24, 23.8, 23.5, 23.6,
06 23.8, 24, 24, 24, 24.7, 25.4, 25, 24.5,
07 24.4, 24.3, 24.3, 24.6, 24.9, 24.5, 25.2,
08 26.1, 25.6, 25.3, 25.7, 25.5, 25.2, 24.5, 25.4)
09 # ES/EN: Se centra el año en 2008 para obtener t / Center year at 2008.
10 t <- años - 2008
11 # ES/EN: Se integran las variables en una tabla / Combine variables in a data frame.
12 datos <- data.frame(año = años, t = t, temperatura = temperatura)
13 # ES/EN: Se ajusta el modelo lineal por mínimos cuadrados / Fit the linear model.
14 modelo_lineal <- lm(temperatura ~ t, data = datos)
15 # ES/EN: Se agrega el término cuadrático / Add the quadratic term.
16 modelo_cuadrático <- lm(temperatura ~ t + I(t^2), data = datos)
17 # ES/EN: Se agrega el término cúbico / Add the cubic term.
18 modelo_cúbico <- lm(temperatura ~ t + I(t^2) + I(t^3), data = datos)
```

Código 1. Fragmento de R empleado para organizar los datos y ajustar los tres modelos.

Modelo	a	b	c	d	R ²	RMSE
Lineal	24.561 3	0.0625	—	—	0.6410	0.4187
Cuadrático	24.560 5	0.0625	0.0000	—	0.6410	0.4187
Cúbico	24.560 5	0.1039	0.0000	-0.0003	0.6938	0.3866

Tabla 3. Coeficientes y medidas de ajuste de los modelos.




Figura 1. Temperaturas observadas y ajustes lineal, cuadrático y cúbico para Chiapas.

Observación del modelo lineal

El modelo lineal muestra una tendencia general ascendente en la temperatura media anual de Chiapas. Su pendiente es aproximadamente de 0.0625 °C por año, lo que indica un incremento promedio durante el periodo 1993–2023.

El modelo presenta un $R^2 = 0.6410$ y un $RMSE = 0.4187$. Sin embargo, al ser una línea recta, no representa adecuadamente las variaciones específicas de algunos años, como los aumentos y disminuciones observados en la gráfica.

Observación del modelo cuadrático

El modelo cuadrático también muestra una tendencia creciente. Sin embargo, el coeficiente cuadrático es muy pequeño, por lo que la curvatura que agrega es prácticamente imperceptible.

Su $R^2 = 0.6410$ y su $RMSE = 0.4187$ son casi iguales a los del modelo lineal. Esto indica que agregar el término cuadrático no mejora de manera significativa la representación de los datos.

Observación del modelo cúbico

El modelo cúbico representa mejor las variaciones de la temperatura, ya que permite que la curva cambie de dirección durante el periodo analizado. En la gráfica se observa un crecimiento inicial, un aumento más marcado en algunos años y una ligera disminución hacia el final.

Este modelo obtiene un $R^2 = 0.6938$ y un $RMSE = 0.3866$, por lo que explica una mayor proporción de la variabilidad y presenta un menor error que los modelos lineal y cuadrático.

Conclusión

Los datos muestran una tendencia general creciente en la temperatura media anual de Chiapas entre 1993 y 2023. El modelo lineal permite observar claramente esta tendencia y es el más sencillo de interpretar. El modelo cuadrático no aporta una mejora importante, debido a que su término de curvatura es muy pequeño.

El modelo cúbico presenta el mejor ajuste de los tres, porque obtiene el mayor valor de (R^2) y el menor $RMSE$. Por ello, es el modelo más adecuado para describir el comportamiento de los datos dentro del periodo estudiado. Sin embargo, para realizar pronósticos futuros debe utilizarse con precaución, ya que los modelos cúbicos pueden generar comportamientos poco confiables fuera del intervalo observado.

Ejercicio 4. Teorema de Bayes

Enunciado: (10 puntos) El cáncer de próstata es el más frecuente entre los varones. Como indicador de si un varón padece cáncer de próstata, los médicos suelen realizar una prueba que mide el nivel de la proteína PSA (antígeno prostático específico), que solo produce la glándula prostática. Aunque unos niveles más altos de PSA son indicativos de cáncer, la prueba es muy poco fiable. De hecho, la probabilidad de que un hombre no canceroso tenga un nivel elevado de PSA es aproximadamente 0.135, probabilidad que aumenta aproximadamente a 0.268 si el hombre tiene cáncer. Si, basándose en otros factores, un médico está seguro en un 65 % de que un varón tiene cáncer de próstata, ¿cuál es la probabilidad condicional de que tenga cáncer si

- (a) la prueba indica un nivel elevado de PSA?
 (b) la prueba no indica un nivel elevado de PSA? Aplique el Teorema de Bayes.

Definimos

C = cáncer.

$\bar{C}$ = no cáncer.

H = PSA elevado.

$\bar{H}$ = PSA no elevado.

Los datos son

$$\begin{aligned} P(C) &= 0.65 \\ P(\bar{C}) &= 0.35 \\ P(H|C) &= 0.268 \\ P(H|\bar{C}) &= 0.135 \end{aligned}$$

a) La prueba indica PSA elevado

Primero se calcula la probabilidad total de obtener PSA elevado. Esta probabilidad incluye dos caminos: tener cáncer y obtener PSA elevado, o no tener cáncer y aun así obtener PSA elevado:

$$P(H) = P(H|C)P(C) + P(H|\bar{C})P(\bar{C})$$

$$P(H) = (0.268)(0.65) + (0.135)(0.35)$$

$$P(H) = 0.1742 + 0.04725 = 0.22145$$

Ahora se aplica el Teorema de Bayes. El numerador representa la probabilidad conjunta de cáncer y PSA elevado:

$$P(C|H) = P(H|C)P(C) / [P(H|C)P(C) + P(H|\bar{C})P(\bar{C})]$$

$$P(C|H) = (0.268)(0.65) / [(0.268)(0.65) + (0.135)(0.35)]$$

$$P(C|H) = 0.1742 / 0.22145$$

$$P(C|H) = 0.7866$$

La probabilidad de cáncer cuando la prueba indica PSA elevado es aproximadamente 78.66 %.

b) La prueba no indica PSA elevado

Cuando no se obtiene un PSA elevado se utiliza el complemento del evento H. Por eso se resta cada probabilidad de 1:

$$P(H|C) = 1 - P(H|C) = 1 - 0.268 = 0.732$$

$$P(H|C) = 1 - P(H|C) = 1 - 0.135 = 0.865$$

Después se calcula la probabilidad total de obtener un resultado no elevado:

$$P(H) = P(H|C)P(C) + P(H|C)P(C)$$

$$P(H) = (0.732)(0.65) + (0.865)(0.35)$$

$$P(H) = 0.4758 + 0.30275 = 0.77855$$

Finalmente se aplica Bayes para calcular la probabilidad de cáncer dado que el PSA no fue elevado:

$$P(C|H) = P(H|C)P(C) / P(H)$$

$$P(C|H) = (0.732)(0.65) / [(0.732)(0.65) + (0.865)(0.35)]$$

$$P(C|H) = 0.4758 / 0.77855$$

$$P(C|H) = 0.6111$$

La probabilidad de cáncer aun cuando la prueba no indica PSA elevado es aproximadamente 61.11 %. Esto ocurre porque la probabilidad previa de cáncer, 65 %, ya era alta.

Ejercicio 5. Análisis de componentes principales

Enunciado: (25 puntos) Realice un análisis de componentes principales (PCA por sus siglas en inglés) aplicado a la base de datos USArrests del paquete básico de R que contiene el porcentaje de asaltos (Assault), asesinatos (Murder) y secuestros (Rape) por cada 100,000 habitantes para cada uno de los 50 estados de USA (1973). Además, también incluye el porcentaje de la población de cada estado que vive en zonas rurales (UrbanPoP). En este caso, el número de variables es $p = 4$ y el número de observaciones es $n = 50$.

- Centralice las variables para que estas tengan media cero. Muestre los resultados en una tabla.
- Calcule la matriz de covarianza. En caso de obtener una variabilidad muy alta, primero estandarice para tener una desviación estándar igual a 1.
- Encuentre los eigenvalores y los eigenvectores de la matriz de covarianza.
- Tomando la mayor cantidad de componentes principales $\min(n - 1, p) = \min(49, 4) = 4$. Calcule los componentes principales y grafique de forma bidimensional a las primeras dos componentes principales.
- Interprete la información que representa cada componente principal.

La base tiene $n = 50$ observaciones y $p = 4$ variables. Primero se resta la media de cada columna. Después se estandariza porque Assault está medido en una escala mucho mayor que las demás variables; de esa manera ninguna variable domina el análisis solo por sus unidades.

a) Centrado y estandarización

Para cada variable se calcula primero la media. La media es la suma de los 50 valores dividida entre 50:

$$\bar{x}_j = \frac{(x_{1j} + x_{2j} + \dots + x_{50j})}{50}$$

$$\bar{x}_{Murder} = \frac{389.4}{50} = 7.788$$

$$\bar{x}_{Assault} = \frac{8538.0}{50} = 170.760$$

$$\bar{x}_{UrbanPop} = \frac{3277.0}{50} = 65.540$$

$$\bar{x}_{Rape} = \frac{1061.6}{50} = 21.232$$

La desviación estándar muestral se calcula con $s_j = \sqrt{\left[\frac{\sum (x_{ij} - \bar{x}_j)^2}{(n - 1)} \right]}$. Por ejemplo, para Murder:

$$s_{Murder} = \sqrt{\left[\frac{929.5528}{(50 - 1)} \right]} = \sqrt{\left(\frac{929.5528}{49} \right)} = \sqrt{18.9705} = 4.3555$$

Para centrar una observación se resta la media de su variable. Por ejemplo, la primera fila corresponde a Alabama:

$$\text{Murder: } 13.2 - 7.788 = 5.412$$

$$\text{Assault: } 236 - 170.760 = 65.240$$

$$\text{UrbanPop: } 58 - 65.540 = -7.540$$

$$\text{Rape: } 21.2 - 21.232 = -0.032$$

Variable	Media	Desv. estándar
Murder	7.788	4.356
Assault	170.760	83.338
UrbanPop	65.540	14.475
Rape	21.232	9.366

Tabla 4. Medias y desviaciones estándar antes de centrar y estandarizar.

Estado	Murder – media	Assault – media	UrbanPop – media	Rape – media
Alabama	5.412	65.240	-7.540	-0.032
Alaska	2.212	92.240	-17.540	23.268
Arizona	0.312	123.240	14.460	9.768
Arkansas	1.012	19.240	-15.540	-1.732
California	1.212	105.240	25.460	19.368
Colorado	0.112	33.240	12.460	17.468
Connecticut	-4.488	-60.760	11.460	-10.132
Delaware	-1.888	67.240	6.460	-5.432
Florida	7.612	164.240	14.460	10.668
Georgia	9.612	40.240	-5.540	4.568
Hawaii	-2.488	-124.760	17.460	-1.032
Idaho	-5.188	-50.760	-11.540	-7.032
Illinois	2.612	78.240	17.460	2.768
Indiana	-0.588	-57.760	-0.540	-0.232
Iowa	-5.588	-114.760	-8.540	-9.932
Kansas	-1.788	-55.760	0.460	-3.232
Kentucky	1.912	-61.760	-13.540	-4.932

Estado	Murder – media	Assault – media	UrbanPop – media	Rape – media
Louisiana	7.612	78.240	0.460	0.968
Maine	-5.688	-87.760	-14.540	-13.432
Maryland	3.512	129.240	1.460	6.568
Massachusetts	-3.388	-21.760	19.460	-4.932
Michigan	4.312	84.240	8.460	13.868
Minnesota	-5.088	-98.760	0.460	-6.332
Mississippi	8.312	88.240	-21.540	-4.132
Missouri	1.212	7.240	4.460	6.968
Montana	-1.788	-61.760	-12.540	-4.832
Nebraska	-3.488	-68.760	-3.540	-4.732
Nevada	4.412	81.240	15.460	24.768
New Hampshire	-5.688	-113.760	-9.540	-11.732
New Jersey	-0.388	-11.760	23.460	-2.432
New Mexico	3.612	114.240	4.460	10.868
New York	3.312	83.240	20.460	4.868
North Carolina	5.212	166.240	-20.540	-5.132
North Dakota	-6.988	-125.760	-21.540	-13.932
Ohio	-0.488	-50.760	9.460	0.168
Oklahoma	-1.188	-19.760	2.460	-1.232
Oregon	-2.888	-11.760	1.460	8.068
Pennsylvania	-1.488	-64.760	6.460	-6.332
Rhode Island	-4.388	3.240	21.460	-12.932
South Carolina	6.612	108.240	-17.540	1.268
South Dakota	-3.988	-84.760	-20.540	-8.432
Tennessee	5.412	17.240	-6.540	5.668
Texas	4.912	30.240	14.460	4.268
Utah	-4.588	-50.760	14.460	1.668
Vermont	-5.588	-122.760	-33.540	-10.032
Virginia	0.712	-14.760	-2.540	-0.532
Washington	-3.788	-25.760	7.460	4.968
West Virginia	-2.088	-89.760	-26.540	-11.932

Estado	Murder – media	Assault – media	UrbanPop – media	Rape – media
Wisconsin	-5.188	-117.760	0.460	-10.432
Wyoming	-0.988	-9.760	-5.540	-5.632

Tabla 5. Variables centradas para los 50 estados. Se muestra cada valor menos la media de su variable.

La fórmula de estandarización es $z_{ij} = \frac{(x_{ij} - \bar{x}_j)}{s_j}$. Para Alabama, por ejemplo, el valor estandarizado de Murder es:

$$z_{Murder, Alabama} = \frac{(13.2 - 7.788)}{4.3555} = \frac{5.412}{4.3555} = 1.2426$$

Por construcción, la suma de cada columna centrada es aproximadamente cero. La estandarización permite comparar las variables en una escala común, con media cercana a 0 y desviación estándar cercana a 1.

```

Fragmento R · Ejercicio 5
01 # ES/EN: PCA con estandarización / PCA with standardization
02 # ES/EN: Se carga la base incorporada en R / Load R's built-in data set.
03 datos <- USArrests
04 # ES/EN: Se centran las variables sin cambiar sus escalas / Center variables only.
05 centrados <- scale(datos, center = TRUE, scale = FALSE)
06 # ES/EN: Se centran y estandarizan las variables / Center and standardize variables.
07 estandarizados <- scale(datos, center = TRUE, scale = TRUE)
08 # ES/EN: Se calcula la matriz de covarianzas de los datos estandarizados.
09 matriz_covarianza <- cov(estandarizados)
10 # ES/EN: Se obtienen valores y vectores propios / Obtain eigenvalues and eigenvectors.
11 descomposicion <- eigen(matriz_covarianza)
12 # ES/EN: Se ejecuta PCA con las variables estandarizadas / Run standardized PCA.
13 pca <- prcomp(datos, center = TRUE, scale. = TRUE)
14 # ES/EN: Se conservan las cuatro componentes / Keep the four components.
15 componentes <- pca$x[, 1:4]
16 # ES/EN: Se dibujan las dos primeras componentes / Plot the first two components.
17 plot(componentes[,1], componentes[,2], type = "n",
18      xlab = "PC1", ylab = "PC2")
19 # ES/EN: Se agregan los nombres de los estados / Add state labels.
20 text(componentes[,1], componentes[,2], rownames(datos), cex = 0.6)

```

Código 2. Fragmento de R para centrar, estandarizar y obtener los componentes principales.

b) Matriz de covarianza

	Murder	Assault	UrbanPop	Rape
Murder	1.0	0.8019	0.0696	0.5636
Assault	0.8019	1.0	0.2589	0.6652
UrbanPop	0.0696	0.2589	1.0	0.4113
Rape	0.5636	0.6652	0.4113	1.0

Tabla 6. Matriz de covarianza de las variables estandarizadas.

La covarianza entre dos variables estandarizadas se calcula como:

$$s_{jk} = \Sigma (z_{ij} - \bar{z}_j) \frac{(z_{ik} - \bar{z}_k)}{(n - 1)}$$

$$s_{Murder, Assault} = \Sigma \frac{(z_{Murder} \cdot z_{Assault})}{49} = \frac{39.2918}{49} = 0.8019$$

Como las variables estandarizadas tienen media cero y desviación estándar uno, la diagonal vale 1. Por eso, en este caso, la matriz de covarianza estandarizada coincide numéricamente con la matriz de correlación. Se observan asociaciones positivas importantes entre Murder, Assault y Rape; UrbanPop presenta relaciones más pequeñas.

c) Eigenvalores y eigenvectores

Los eigenvalores y eigenvectores se obtienen resolviendo la ecuación característica de la matriz R. Si R es la matriz de covarianza estandarizada, se busca cada valor λ que cumple:

$$\det(R - \lambda I) = 0$$

Para cada eigenvalor se calcula un eigenvector v resolviendo $(R - \lambda I)v = 0$. R devuelve cuatro pares porque $p = 4$: un eigenvalor, un eigenvector y una componente principal por cada dirección.

Componente	Eigenvalor	Varianza explicada (%)	Acumulada (%)
PC1	2.4802	62.01	62.01
PC2	0.9898	24.74	86.75
PC3	0.3566	8.91	95.66
PC4	0.1734	4.34	100.00

Tabla 7. Eigenvalores y porcentaje de varianza explicado.

La proporción de varianza explicada por cada componente se calcula dividiendo su eigenvalor entre la suma de todos los eigenvalores:

$$\text{Varianza explicada de PCk} = \lambda \frac{k}{(\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4)} \times 100$$

$$PC1: \frac{2.4802}{(2.4802 + 0.9898 + 0.3566 + 0.1734)} \times 100 = 62.01 \%$$

$$PC1 + PC2: \frac{(2.4802 + 0.9898)}{4} \times 100 = 86.75 \%$$

Variable / Variable	PC1	PC2	PC3	PC4
Murder	0.5359	0.4182	0.3412	0.6492
Assault	0.5832	0.188	0.2681	-0.7434
UrbanPop	0.2782	-0.8728	0.378	0.1339
Rape	0.5434	-0.1673	-0.8178	0.089

Tabla 8. Eigenvectores o cargas de las variables en cada componente.

El primer componente explica aproximadamente 62.01 % de la variación total; los dos primeros explican aproximadamente 86.75 %. Por eso una gráfica de PC1 y PC2 resume gran parte de la información de las cuatro variables.

d) Componentes principales y gráfica

Cada componente principal se obtiene multiplicando cada variable estandarizada por su carga y sumando los cuatro productos. Para PC1:

$$PC1 = 0.5359z_{Murder} + 0.5832z_{Assault} + 0.2782z_{UrbanPop} + 0.5434z_{Rape}$$

Para Alabama, $z = (1.2426, 0.7828, -0.5209, -0.0034)$. Se sustituyen los cuatro valores:

$$PC1_{Alabama} = (0.5359)(1.2426) + (0.5832)(0.7828) + (0.2782)(-0.5209) + (0.5434)(-0.0034)$$

$$PC1_{Alabama} = 0.6659 + 0.4565 - 0.1449 - 0.0019 = 0.9756$$

El mismo procedimiento se repite para PC2, PC3 y PC4 y para cada uno de los 50 estados; los resultados se muestran en la tabla.

Estado	PC1	PC2	PC3	PC4
Alabama	0.976	1.122	0.440	0.155
Alaska	1.931	1.062	-2.020	-0.434
Arizona	1.745	-0.738	-0.054	-0.826
Arkansas	-0.140	1.109	-0.113	-0.181
California	2.499	-1.527	-0.593	-0.339
Colorado	1.499	-0.978	-1.084	0.001
Connecticut	-1.345	-1.078	0.637	-0.117
Delaware	0.047	-0.322	0.711	-0.873
Florida	2.983	0.039	0.571	-0.095
Georgia	1.623	1.266	0.339	1.066
Hawaii	-0.903	-1.555	-0.050	0.894

Estado	PC1	PC2	PC3	PC4
Idaho	-1.623	0.209	-0.257	-0.494
Illinois	1.365	-0.675	0.671	-0.121
Indiana	-0.500	-0.150	-0.226	0.420
Iowa	-2.231	-0.103	-0.163	0.017
Kansas	-0.789	-0.267	-0.025	0.204
Kentucky	-0.743	0.949	0.028	0.664
Louisiana	1.549	0.862	0.776	0.450
Maine	-2.373	0.373	0.065	-0.327
Maryland	1.746	0.423	0.156	-0.553
Massachusetts	-0.481	-1.460	0.603	-0.178
Michigan	2.087	-0.154	-0.381	0.101
Minnesota	-1.676	-0.626	-0.152	0.067
Mississippi	0.986	2.370	0.733	0.213
Missouri	0.690	-0.261	-0.374	0.224
Montana	-1.174	0.531	-0.244	0.122
Nebraska	-1.253	-0.192	-0.174	0.016
Nevada	2.846	-0.768	-1.152	0.311
New Hampshire	-2.360	-0.018	-0.036	-0.033
New Jersey	0.180	-1.435	0.757	0.241
New Mexico	1.960	0.141	-0.182	-0.336
New York	1.666	-0.815	0.637	-0.013
North Carolina	1.112	2.206	0.855	-0.945
North Dakota	-2.962	0.593	-0.298	-0.251
Ohio	-0.224	-0.735	0.031	0.469
Oklahoma	-0.309	-0.285	0.015	0.010
Oregon	0.059	-0.536	-0.930	-0.235
Pennsylvania	-0.879	-0.565	0.397	0.355
Rhode Island	-0.855	-1.477	1.356	-0.607
South Carolina	1.307	1.914	0.298	-0.130
South Dakota	-1.968	0.815	-0.385	-0.108
Tennessee	0.990	0.852	-0.186	0.646

Estado	PC1	PC2	PC3	PC4
Texas	1.342	-0.408	0.487	0.637
Utah	-0.545	-1.457	-0.291	-0.081
Vermont	-2.773	1.388	-0.833	-0.143
Virginia	-0.095	0.198	-0.012	0.209
Washington	-0.215	-0.960	-0.619	-0.219
West Virginia	-2.087	1.411	-0.104	0.131
Wisconsin	-2.059	-0.605	0.137	0.182
Wyoming	-0.623	0.318	0.238	-0.165

Tabla 9. Componentes principales de los 50 estados.




Figura 2. Estados de Estados Unidos representados en las dos primeras componentes principales.




Figura 3. Porcentaje de varianza explicado por cada componente.

e) Interpretación de los componentes

PC1. combina con cargas positivas altas Murder, Assault y Rape. Puede interpretarse como un eje general de violencia delictiva: los estados con puntuaciones altas tienden a presentar valores altos en esas tres variables.

PC2. está dominada por UrbanPop y tiene cargas negativas menores en las variables de delito. Representa principalmente una diferencia relacionada con el porcentaje de población urbana, separando estados con mayor urbanización de estados con menor urbanización relativa.

PC3. recibe una carga positiva importante de Rape y cargas negativas en las otras variables. Ayuda a distinguir estados donde el comportamiento de Rape es relativamente alto respecto del patrón conjunto.

PC4. contiene contrastes entre Murder y Assault y aporta la parte restante de la variación. Su importancia es menor porque explica solo una fracción pequeña de la variabilidad total.

Ejercicio 6. Genes mirror geography within Europe

Enunciado: (15 puntos) Lea el artículo Genes mirror geography within Europe, que se encuentra en la carpeta de referencias compartida de Drive. Explique de forma resumida de qué se trata el artículo y realice una conclusión de cómo el algoritmo de componentes principales es de gran utilidad en la reducción de la dimensionalidad.

El artículo estudia la relación entre la variación genética y la ubicación geográfica de personas europeas. Los autores analizaron aproximadamente 3,000 individuos y más de medio millón de sitios variables del ADN. Aunque las diferencias genéticas promedio entre europeos son pequeñas, los resultados muestran que las personas de regiones cercanas suelen tener perfiles genéticos más parecidos que las personas de regiones lejanas.

Para resumir una cantidad tan grande de variables, los autores utilizaron componentes principales. Al representar los individuos con las primeras componentes, apareció una figura parecida al mapa de Europa: se distinguieron la península ibérica, Italia, el sureste europeo, Chipre y Turquía, además de diferencias dentro de algunos países. Esto no significa que el PCA dibuje un mapa geográfico de manera literal; significa que las principales direcciones de variación genética conservan una estructura relacionada con la geografía.

El PCA es útil para reducir la dimensionalidad porque transforma muchas variables correlacionadas en pocas componentes que conservan la mayor parte de la variación. Así, un conjunto difícil de visualizar puede estudiarse en dos o tres dimensiones, detectando grupos, gradientes y observaciones atípicas. En este artículo, la reducción permitió observar una estructura poblacional que habría sido difícil de identificar revisando cientos de miles de marcadores uno por uno. También es importante considerar sus límites: las componentes facilitan la visualización y el resumen, pero no sustituyen el análisis científico de las causas ni eliminan por sí solas los posibles sesgos de la estructura poblacional.

Referencias

- Novembre, J., Johnson, T., Bryc, K., Kutalik, Z., Boyko, A. R., Auton, A., Indap, A., King, K. S., Bergmann, S., Nelson, M. R., Stephens, M., & Bustamante, C. D. (2008). Genes mirror geography within Europe. *Nature*, 456(7218), 98–101. <https://doi.org/10.1038/nature07331>
- R Core Team. (2023). R: A language and environment for statistical computing. R Foundation for Statistical Computing. <https://www.R-project.org/>
- Servicio Meteorológico Nacional. (2024). Temperaturas promedio del Estado de México 1993–2023 [Conjunto de datos]. Comisión Nacional del Agua, México.
- U.S. Census Bureau. (1973). USArrests: Violent crime rates by state [Conjunto de datos]. <https://stat.ethz.ch/R-manual/R-devel/library/datasets/html/USArrests.html>
- Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9ª ed.). Pearson Educación.